

```
@page { size: A4; margin: 1.5cm 1.8cm; } body { font-family: 'SimSun', serif; font-size: 8.5pt; line-height: 1.42; color: #222; } h1 { font-size: 12pt; text-align: center; margin: 0 0 8px 0; } h2 { font-size: 10pt; margin: 10px 0 3px 0; border-bottom: 0.7px solid #555; padding-bottom: 1px; } h3 { font-size: 9pt; margin: 6px 0 2px 0; } table { border-collapse: collapse; width: 100%; margin: 4px 0; font-size: 7.5pt; } th, td { border: 0.5px solid #999; padding: 1px 5px; text-align: left; } th { background: #ebeb; font-weight: bold; } ul, ol { margin: 1px 0; padding-left: 18px; } li { margin: 0; } p { margin: 2px 0; text-align: justify; } code { font-size: 7pt; background: #f4f4f4; padding: 0 2px; }
```

单目深度估计避障提示系统 — 中期进展报告

一、项目简介

本项目基于自监督单目深度估计方法 Monodepth2 [1]，利用 KITTI 车载数据集 [2] 训练模型从单帧 RGB 图像预测像素级深度图，并计划开发辅助驾驶避障提示功能。自监督方案仅依赖连续视频帧的光度重投影误差，无需昂贵的深度传感器标注，适合计算资源有限的小型实操项目。

二、数据处理

使用 KITTI Raw Dataset 公开数据，覆盖 4 个采集日期、37 个驾驶序列，共 18201 个同步图像-点云配对样本。经 7 步标准化流水线（元数据提取→质量分析→数据集划分→深度图生成→统计可视化→格式转换→启动训练）处理后，剔除 11 个异常样本，清洗后共 18190 样本。按序列整体划分确保无场景泄露：训练集 14109 (77.6%)、验证集 2369 (13.0%)、测试集 1712 (9.4%)。四种原始分辨率（ 375×1242 / 370×1224 / 374×1238 / 370×1226 ）统一缩放至 192×640 。

已验证的关键点：(1) 图像按 frame_id 精确匹配点云文件，避免排序错配；(2) LiDAR 点云集中在 118K~122K 点/帧，投影后可提供完整深度监督；(3) 序列首尾帧自动过滤（缺少相邻帧无法构成训练对）。

三、模型设计与训练

方法原理：Monodepth2 采用深度网络（ResNet18 编码器 + 多尺度解码器）+ 位姿网络（独立 ResNet18）双网络架构。利用预测深度和位姿将相邻帧重投影到目标视角，以 SSIM+L1 混合光度误差为监督信号。关键设计包括自动掩膜（屏蔽静止像素）、最小重投影误差（解决遮挡）和多尺度联合优化。

训练配置：完成两轮训练实验，均使用 RTX 4060 Laptop (8GB)、PyTorch 2.5.1、输入分辨率 192×640 、Adam 优化器。V2 主要改进：epoch 翻倍（20→40）、batch size 增大（6→8）、平滑系数提升（ $1e-3 \rightarrow 1.5e-3$ ）、学习率经两次衰减（ $1e-4 \rightarrow 1e-5 \rightarrow 1e-6$ ）。

V2 训练结果（总步数 70,000，log frequency=250）：

阶段	Epoch	Train Loss 均值	Val Loss 均值	趋势
Q1	1-10	0.1191	0.1143	快速下降
Q2	11-20	0.0840	0.0881	稳步收敛
Q3	21-30	0.0684	0.0810	进入微调
Q4	31-40	0.0700	0.0760	收益收窄

Train Loss 从 0.1461 降至 0.0610 (-58.2%)，Val Loss 从 0.1520 降至 0.0520 (-65.8%)，Val 平滑最优出现在 epoch 30 附近 (step 52000)。训练正常收敛，无明显过拟合；后期收益收窄但仍缓慢改善。

四、遇到的问题及解决方案

- 1. **图像与点云文件名错配**：2011_09_30 序列文件名不严格对应，按文件名排序配对导致错位。改为按 frame_id 精确匹配。
- 2. **多分辨率处理**：四个日期相机型号不同，输出四种分辨率。统一缩放至 192×640 简化数据加载。
- 3. **序列首尾帧缺失相邻帧**：Monodepth2 需前向+后向帧构建训练对。格式转换时自动过滤首尾帧。
- 4. **GPU 显存限制**：默认 batch=12 导致 OOM。经逐步测试确定 batch=8 为稳定上限，配合低分辨率确保训练正常完成。
- 5. **V1 训练不充分**：20 epoch 后 Loss 仍在下滑。V2 翻倍至 40 epoch，增加第二次 LR 衰减 (epoch 30)，Train Loss 在 V1 基础上进一步下降约 40%。

五、当前进度与后续计划

已完成：(1) KITTI 数据下载与 7 步清洗流水线；(2) LiDAR 深度图投影与 5 类统计可视化；(3) Monodepth2 V1 (20 epochs, AbsRel=0.101) 与 V2 (40 epochs, Train Loss -58%) 两轮训练；(4) 单图推理验证；(5) GitHub 代码仓库与文档。

后续计划 (第 11-16 周)：(1) 对 V2 epochs 30/35/40 权重做全量验证集评估，选出最优模型；(2) 设计避障提示规则 (距离阈值 + ROI 区域划分)；(3) 开发可视化叠加界面 (深度热力图 + 红光警示)；(4) 引入 Lite-Mono [3] 进行精度-速度对比实验；(5) 录制演示视频并撰写最终技术报告 (3000~5000 字)。

参考文献

[1] C. Godard et al., "Digging into Self-Supervised Monocular Depth Estimation," ICCV 2019. [2] A. Geiger et al., "Vision meets Robotics: The KITTI Dataset," IJRR 2013. [3] N. Zhang et al., "Lite-Mono: A Lightweight CNN and Transformer Architecture for Self-Supervised Monocular Depth Estimation," CVPR 2023.